MACHINE LEARNING CANVAS

Designed for: MiBici | Designed by: **Equipo 44** | Date: 18/10/2026 | Iteration: 1 .

PREDICTION TASK

What is the type of task?
Which entity are predictions made on?
What are the possible outcomes to predict?
When are outcomes observed?

P1 (Regresión): Predecir la cantidad de viajes que iniciarán en una estación durante la siguiente hora.

P2 (Clasificación): Identificar estaciones con alto riesgo de quedarse sin bicicletas o sin anclajes disponibles.

P3 (Clustering): Agrupar estaciones según sus patrones históricos de uso.

Las predicciones se realizarán a nivel estación-hora. El clustering analizará patrones acumulados durante el periodo de estudio.

DECISIONS

How are predictions turned into actionable recommendations or decisions for the end-user? (Mention parameters of the process / application for this.)

Los resultados apoyarán la toma de decisiones operativas de MiBici:

P1: Planificar la distribución de bicicletas según la demanda prevista.

P2: Priorizar estaciones que requieren revisión o redistribución de bicicletas.

P3: Identificar zonas con comportamientos similares para apoyar la planeación y expansión del sistema.

VALUE PROPOSITION

Who is the end beneficiary, and what specific pain points are addressed?
How will the ML solution integrate with their workflow, and through which user interfaces?

La solución busca mejorar la eficiencia operativa del sistema MiBici mediante el análisis de datos históricos y modelos predictivos.

Los principales beneficiarios serán los operadores del sistema, los equipos de rebalanceo y los responsables de planeación urbana.

El correcto funcionamiento de la operación de MiBici busca brindar un mejor servicio y una mejor experiencia a los usuarios del área metropolitana de Guadalajara.

Los resultados podrían integrarse en tableros y mapas que permitan anticipar las demandas y conocer el impacto en cada estación.

DATA COLLECTION

How is the initial set of entities and outcomes sourced (e.g., database extracts, API pulls, manual labeling)?
What strategies are in place to update data continuously while controlling cost and maintaining freshness?

Se utilizarán dos años de registros históricos de viajes del sistema MiBici, correspondientes al periodo de los ultimos 24 meses.

Los datos se obtendrán de los archivos mensuales CSV publicados en el portal de datos abiertos de MiBici, mediante un proceso automatizado y reproducible desarrollado en Python.

La información se someterá a procesos de limpieza, normalización y transformación para posteriormente almacenarse en formato Parquet, adecuado para grandes volúmenes de información..

DATA SOURCES

Where can we get data on entities and observed outcomes? (Mention internal and external database tables or API methods.)

La principal fuente de información será el portal oficial de datos abiertos de MiBici, que proporciona:

- Registros mensuales de viajes: fechas, horarios, estaciones de origen y destino.

- Nomenclatura de estaciones: identificadores, nombres, ubicación geográfica y capacidad.

Se trabajará con 24 archivos mensuales de viajes y la información de estaciones correspondiente al periodo analizado.

Los datos se utilizarán principalmente de forma agregada, evitando el uso de información personal innecesaria.

IMPACT SIMULATION

What are the cost/gain values for (in)correct decisions?
Which data is used to simulate pre-deployment impact?
What are the criteria for deployment?
Are there fairness constraints?

Las decisiones incorrectas en las preguntas 1 y 2 pueden generar un impacto negativo en la administración de las estaciones de bicicletas y por consecuencia generar un malestar entre los usuarios. Por otro lado la pregunta 3 genera un impacto negativo diferente al hacer posible que se generen expansiones del sistema innecesarias.
Para la simulación del impacto pre-despliegue se usan datos de prueba segmentados.
Para decidir hacer el despliegue del proyecto se tiene que llegar a ciertos puntajes por determinar con los modelos escogidos para la respuesta de cada pregunta.
Los datos con los que contamos no tienen sesgos que podrían impactar en las predicciones del modelo

MAKING PREDICTIONS

Are predictions made in batch or in real time?
How frequently?
How much time is available for this (including featurization and decisions)?
Which computational resources are used?

Los modelos P1 y P2 generarán predicciones por estación para la siguiente hora, utilizando los datos históricos disponibles.

El modelo P3 agrupará las estaciones de manera periódica según sus patrones de uso.

Las predicciones se ejecutarán por lotes mediante Python.

BUILDING MODELS

How many models are needed in production?
When should they be updated?
How much time is available for this (including featurization and analysis)?
Which computation resources are used?

Se necesitan un total de 3 modelos en producción, dado que se van a contestar diferentes preguntas el número mínimo sería 3 para que cada modelo tenga un modelo entrenado para la resolución del problema planteado en cada pregunta.

Los modelos deben actualizarse mensualmente especialmente el de regresión, dado que mes con mes tiene información que puede ayudar a refinar la calidad de sus predicciones.

Se cuenta con 5 semanas para la realización del proyecto. Se usan recursos computacionales propios y se puede

FEATURES

What representations are used for entities at prediction time?
What aggregations or transformations are applied to raw data sources?

Los datos se transformarán en variables por estación y hora, utilizando las siguientes características:

- Temporales: Hora, día de la semana, mes y fin de semana.

- Históricas: Viajes de 1, 24 y 168 horas anteriores y promedios móviles de 24 horas.

- Estaciones: Capacidad, latitud y longitud.

- P2 (Clasificación): Llegadas, salidas y flujo neto histórico para estimar el riesgo de desequilibrio.

- P3 (Clustering): Promedio diario de viajes, proporción de uso matutino y

llegar a usar recursos en la nube.

actividad en fines de semana.

Se completarán los periodos sin viajes y se utilizará únicamente información histórica disponible para evitar fugas de datos futuros.

MONITORING

Which metrics and KPIs are used to track the ML solution's impact once deployed, both for end-users and for the business? How often should they be reviewed?

Las métricas seleccionadas para cada modelo son:

- Regresión: MAE y RMSE
- Clasificación: Accuracy, f1 y recall
- Clustering: Silhouette score.

Las métricas deben monitorearse constantemente para confirmar que el modelo mantiene la calidad adecuada.



Version 1.2. Created by Louis Dorard, Ph.D. Licensed under a Creative Commons Attribution-ShareAlike 4.0 International License.
Please keep this mention and the link to ownml.co when sharing.

OWNML.CO

What your canvas is for

A filled canvas does 4 jobs, and each one needs certain boxes filled in with care.

- **Deciding what's worth building.** Put each idea on its own canvas and you can compare the ideas on the same terms: what each could gain in a year, and whether the outcomes a model would learn from were ever recorded. That takes dollar amounts in the Impact Simulation box, and a named person in the Value Proposition box who acts on each prediction.
- **Agreeing on what gets built.** Some of the choices that set a system's value look technical, but they're business decisions. What counts as a lost customer: 60 days without buying, or 90? How far ahead do you predict? How many flagged cases can your team act on? On the canvas, business, data and engineering make these choices together, instead of leaving them to whoever writes the code.
- **Knowing when the model is good enough.** The Impact Simulation box sets the performance the model has to reach to pay off. Test the model on enough of the cases you're predicting: 35,000 machine-hours of data can hold just 3 failures, too few to measure anything.
- **Learning after launch.** If acting on a prediction changes the outcome, keep a small share of flagged cases untouched and record that share in the Decisions box, so you can see what your action changed.

Book a project review

Louis Dorard created the canvas in 2015. Book a free 30-minute call, then send him your canvas draft, or a few lines about the project if you haven't started one. He prepares the call from what you send, and you'll leave knowing where the project is likely to break, and what to check before anyone builds it.

Book a 30-minute call →

Reference the Machine Learning Canvas

If you need to reference the Canvas formally (e.g. in documentation or publications), you may use:

```
@misc{mlc,
  title  = "Machine Learning Canvas",
  author = "Louis Dorard (OWNML)",
  url    = "https://www.ownml.co/",
  year   = "2015"
}
```

Whatever you can't answer is the work left before anyone writes code.

"The Canvas allowed us to structure and focus our delivery sprints. The ML system went live in June 2020 and still is."
— Christian Schiller, Senior IT & Enterprise Architect, Deutsche Telekom

"MLC played an essential role in a positive project outcome. It is now being used throughout the organization."
— Daitan, now part of Coforge, a global IT services firm